

文本何时有助于时间序列预测

多领域严格时点反事实检验与安全回退

SafeFAME TS 人工智能课程设计报告

课程名称 人工智能

作业性质 个人课程设计

姓名学号 _____

提交日期 _____

摘要

外部文本可能解释时间序列变化，也可能因发布时间不明、主题漂移或样本量有限而造成负迁移。本文以 Time-MMD 为主数据，研究在严格时点约束下文本是否能为多领域预测提供可泛化的增量信息。研究覆盖气候、能源、经济、交通、农业和安全六个领域，构造 18 项领域与预测跨度任务；另在 ETTh1、ETTh2 上进行六项长跨度数值外部验证。文本侧仅使用 fact，排除数据中生成式预测字段 preds；共保留 14281 条去重事实，并要求事实 end_date 早于预测起点。需强调，end_date 只是数据提供的可得时间代理，不等同于已核验的真实发布时间。

本文提出 SafeFAME-TS v2。系统先从 Last、季节朴素、AR-Ridge、DLinear-M 与 PatchTST 中按验证校准段选择数值回退，再构造语义残差和频率语义残差候选。验证期后半独立用于资格判定：候选必须总体超过回退、在决策段前后两半均胜出，并在 99 次文本错位置换中达到每任务两条候选 Bonferroni 校正后的 $p \leq 0.025$ 。测试期采用 5000 次移动块 Bootstrap 评估重叠预测窗口下的损失差区间。外部审查后另做 999 次循环移位置换和匹配容量纯数值残差对照，作为不改变冻结路由的敏感性检查。

冻结规则没有在 18 项任务中放行任何文本路径。测试期事后分析显示，语义候选虽在 13/18 项任务取得更低点估计 MSE，但只有 3 项 95% 移动块区间完全支持改善，同时有 4 项区间完全支持变差；频率候选仅在 8/18 项任务取得点估计改善。数值外部验证中，PatchTST-M 在六项 ETT 任务均优于所比较的非 PatchTST 基线，平均 MSE 改善 12.69%。扰动实验表明其对高斯噪声与 10% 随机缺失的平均退化分别为 3.31% 和 1.68%，但对尖峰和末段连续缺失平均退化达 84.38% 和 24.59%。

结果说明，文本价值不能由少数测试任务或模型复杂度推断，必须在预测时点约束、反事实对照和独立选择协议下逐任务验证。999 次循环移位检验仍无候选达到 $p \leq 0.025$ ；相对于匹配容量纯数值残差对照，只有 2 条候选的测试期区间完全大于零，9 条完全小于零。SafeFAME-TS v2 的主要贡献是将是否启用文本转化为可证伪的统计决策，并在当前证据不足时保留数值回退；结论不应外推为文本在所有时间序列任务中无效。

关键词 多模态时间序列预测 时点对齐 文本置换 移动块 Bootstrap 安全回退 负迁移

目录

1 问题重述与研究目标
2 相关研究与方案依据
3 数据审计与预处理
4 模型假设与符号
5 SafeFAME TS v2 模型
6 实验设计与求解
7 实验结果
8 稳健性与误差分析
9 系统实现与可复现性
10 模型评价与结论
参考文献
附录

1 问题重述与研究目标

课程设计要求形成完整的问题描述、系统或实验设计、算法描述、实验结果与分析图表，并提交源代码和详细实验过程资料。结合时间序列研究基础，本文把任务定义为：在只能使用预测起点前信息的条件下，判断外部事实文本是否改善未来多步预测，并设计一个在文本证据不足时不会被迫采用文本的系统。

1.1 研究问题

- RQ1 严格时点文本语义是否稳定超过纯数值预测。
- RQ2 正确对齐文本是否超过随机置换文本。
- RQ3 频率与语义交互是否提高跨跨度稳定性。
- RQ4 验证期选择能否避免已观察到的文本负迁移。
- RQ5 数值骨干能否在外部数据和输入扰动下保持可复现性能。

1.2 闭环对应关系

表 1 原题要求 数据 方法 输出与验证对应

要求	数据证据	模型方法	输出	验证
问题与数据	六领域数值和 fact	时点索引	18 项任务	审计日志
算法设计	历史窗口和文本	专家池与残差候选	多步预测	基线比较
改进路线	覆盖和频率特征	文本置换与安全选择	路径决策	分段门槛
实验结果	2764 个测试起点	冻结后评估	MSE MAE RMSE	块 Bootstrap
系统实现	结果 CSV	交互原型	任务审计视图	复现脚本

2 相关研究与方案依据

表 2 相关研究 证据等级与本文取舍

研究	身份	主要启发	本文使用边界
Time-MMD	NeurIPS 2024	多领域数值与文本对齐数据	提供数据基础；不照抄其结论
DLinear	AAAI 2023	分解线性预测与强简单基线	作为可解释深度基线
PatchTST	ICLR 2023	分块与通道独立	作为主要数值专家
TimesNet / FEDformer	ICLR 2023 / ICML 2022	多周期与频域建模	启发频率统计分支
TimeXer	NeurIPS 2024	外生变量建模	支持将文本视为外生信息
Time-LLM / TimeCMA	ICLR 2024 / AAAI 2025	语言模型重编程与跨模态对齐	说明融合方法空间；本文采用轻量实现
T3Time	AAAI 2026	时域 频域 提示三支与跨度条件门控	借鉴多模态和跨度条件思想
Spectral Text Fusion	2026 预印本	频谱与文本交互	启发候选频率交互；须独立验证

PatchTST 的分块与通道独立结构[2]、DLinear 对简单基线的强调[3]、TimesNet 与 FEDformer 的多周期或频域建模[4,6]共同构成数值侧依据。iTransformer 与 TimeXer 分别讨论变量中心表示和外生变量[7-8]。文本侧以 Sentence-BERT 和 MiniLM 提供轻量句向量[10-11]。Time-LLM 与 TimeCMA 展示语言表征与时间序列对齐的不同路径[9,12]。本文没有复现所有大型模型，因为研究变量是“文本是否提供增量信息”，不是模型排行榜；使用冻结编码与线性残差头可以降低容量混杂。

TimeCMA 已正式发表于 AAAI 2025[12]。T3Time 的正式题名为 Tri-Modal Time Series Forecasting via Adaptive Multi-Head Alignment and Residual Fusion，已发表于 AAAI 2026[13]；本文借鉴其时域、频域和提示三支以及跨度条件门控，不再把它误写为测试时训练。Spectral Text Fusion 截至核验时仍为 arXiv:2602.01588 预印本[14]，只作为频谱与文本交互启发，不直接采用其报告数字作为本文证据。

3 数据审计与预处理

3.1 数据身份与范围

主数据来自 Time-MMD 官方论文和官方仓库[1]。本文选取六个领域，覆盖周频与月频、单变量与多变量、长序列与少样本。原始文件保留不变，所有清洗结果写入 data_processed 和 outputs。

表 3 六领域数值数据与排序审计

领域	行数	数值列	起始	结束	重排数	OT 缺失
Agriculture	532	3	1980-01	2024-04	0	0
Climate	1272	8	2000-01	2024-05	1272	0
Economy	447	3	1987-01	2024-03	447	0
Energy	1622	9	1993-04	2024-04	0	0
Security	309	1	1998-09	2024-05	0	0
Traffic	651	1	1970-01	2024-03	0	0

3.2 数值预处理

先解析日期区间并按 `start_date`、`end_date` 稳定升序排序。目标 OT 以训练期均值和总体标准差标准化，验证与测试只使用训练期参数。多变量模型的各数值列同样以训练期统计量标准化。样本按滑动窗口构造，但训练、验证和测试边界处不允许目标跨段。

$$\tilde{x}_t = (x_t - \mu_{\text{train}}) / \sigma_{\text{train}} \quad (1)$$

3.3 文本预处理与泄漏控制

只保留非空 `fact`，排除 `preds` 与 `pred`；同领域同来源的规范化完全重复事实只保留最早结束区间。对预测起点 `t`，文本必须位于同一历史窗口内且满足 `end_date < t`。该规则比允许同周期文本更保守，但 `end_date` 并非经外部核验的发布日期，因此结果仍属于基于可得时间代理的回溯。




图 1 严格时点约束下各领域文本覆盖

去重语料共 14281 条；每个样本每来源最多选 32 条。文本中含 forecast、will、expect 等未来措辞仅作为审计特征而不会自动删除，因为这些措辞可能出现在预测起点前已发布的历史报告中。模型同时接收来源缺失、可用和选中数量、文本年龄与未来措辞比例等 10 维质量特征。

4 模型假设与符号

4.1 模型假设

- 在每个数据文件内部，稳定升序后的日期能够表示观测先后顺序。
- 训练期标准化参数可用于后续时间段；明显分布漂移将作为误差来源而非被隐去。
- end_date 早于预测起点是文本可得性的必要代理条件，但不是充分的真实发布日期证明。
- 同一任务内逐预测起点损失存在局部相关，因此区间估计按连续块重采样。
- 验证段能够用于有限的模型与路径选择；小样本任务的统计功效可能不足。

4.2 主要符号

表 4 主要符号与含义

符号	含义	类型或单位
X_t	截至预测起点的长度 L 数值窗口	标准化数值
$Y_{t:H}$	未来 H 步 OT 目标	标准化数值
Z_t	report 与 search 事实的聚合向量	384+384=768 维后降维
q_t	文本覆盖 年龄 来源与措辞质量	10 维特征
b_t	验证期选定的数值回退预测	H 维
r_t	文本残差候选预测	H 维
α	Ridge 正则系数	超参数
pperm	文本置换检验经验 p 值	0 至 1

5 SafeFAME TS v2 模型

5.1 数值专家池

专家包括 Last、SeasonalNaive、AR-Ridge、DLinear-M 与 PatchTST。Last 复制窗口最后值；季节朴素使用对应周期滞后；AR-Ridge 把长度 L 窗口映射至 H 步；DLinear-M 对趋势与季节分量建立线性映射；PatchTST 将单目标窗口切为重叠 patch 并用 Transformer 编码。专家选择只根据校准段 MSE。

$$m^* = \arg \min_m \text{MSE_calibration}(m) \quad (2)$$

5.2 文本聚合

事实向量由冻结 all-MiniLM-L6-v2 生成。报告与搜索文本分开聚合，权重仅由事实年龄决定；质量特征不进入聚合权重，而是在残差模型中作为独立输入。这一区分保证公式与代码一致。

$$z_i = \text{Normalize}(\Sigma_i w_i e_i / \Sigma_i w_i), w_i = \exp(-\ln 2 \cdot \text{age}_i / \tau) \quad (3)$$

5.3 语义与频率残差候选

语义候选的设计矩阵由标准化历史窗口、训练期拟合的 PCA 语义主成分和标准化质量特征组成。频率候选额外加入窗口频率统计及其与语义主成分前 8 维的乘积交互。两者预测 Last 锚点的 H 步残差，而不是直接与任意数值专家输出拼接。由于路径资格比较对象是校准选出的数值回退，候选相对回退的差异同时包含残差结构和文本输入，不能直接称为纯文本效应。本文因此增加结构匹配的纯数值残差对照：语义路径对照只保留数值窗口，频率路径对照保留数值窗口和频率统计。

$$\hat{\delta} = \arg \min_{\delta} \{ \Sigma_i \|Y_i - \text{Last}(X_i) - \Phi(X_i, Z_i, q_i) \delta\|_2^2 + \alpha \|\delta\|_2^2 \} \quad (4)$$

5.4 资格判定与输出

验证期按时间对半。前半选择数值专家、Ridge 正则和深度模型早停轮数；后半保持未见，用于文本路径资格。冻结协议对每个候选执行 99 次文本与质量行置换，经验 p 值采用加一校正。

Bonferroni 校正族定义为同一领域与跨度任务内的语义和频率两条候选，因此阈值取 $0.05/2=0.025$ ；该校正不覆盖 18 项任务之间的探索性测试期区间。99 次置换的 p 值分辨率仅为 0.01，所以另以固定原校准正则系数的 999 次循环移位置换做敏感性检查。循环移位保留各数据段内部文本序列的局部结构，只破坏文本与数值起点的同步关系。

$$p_{\text{perm}} = [1 + \#(\text{MSE_perm} \leq \text{MSE_aligned})] / (99 + 1) \quad (5)$$

$$\hat{y} = r_{\text{best}} \text{ (总体胜出且两段均胜出且 } p_{\text{perm}} \leq 0.025 \text{)}, \text{ 否则 } \hat{y} = b \quad (6)$$

5.5 算法过程

表 5 SafeFAME TS v2 算法步骤

步骤	输入	处理	输出
1	原始 CSV	日期稳定排序 训练期标准化	时间窗口
2	fact 与日期	去重 严格时点索引 冻结编码	Z 与 q
3	训练和校准	训练五类专家并按校准 MSE 选回退	b
4	训练和校准	PCA 与 Ridge 选择语义 频率候选	候选参数
5	独立决策段	总体 分段 99 次置换	资格标记

步骤	输入	处理	输出
6	训练加验证	按冻结参数重训	最终模型
7	测试	MSE MAE RMSE 和移动块区间	结果与审计

6 实验设计与求解

6.1 数据划分与独立样本单位

Time-MMD 每个领域按 70%训练、10%验证、20%测试顺序划分，验证再分为校准和路径决策。18 项任务共 648 个校准起点、655 个决策起点和 2764 个测试起点。独立统计单位是预测起点，而非每个 H 步误差；每个起点先对 H 步和变量取平均损失。

6.2 超参数与训练

表 6 核心超参数

模块	设置
随机种子	2026 2027 2028
深度训练	AdamW 学习率 3e-4 权重衰减 1e-4 最大 60 轮 patience 8
PatchTST	d_model 32 四头 两层 d_ff 64 dropout 0.1
语义 PCA	768 维拼接输入 最多保留 24 维 仅训练期拟合
Ridge α	1e-4 至 1e4 候选
冻结置换	99 次逐行错位 加一经验 p 值
敏感性置换	999 次循环移位 固定原校准 α
移动块 Bootstrap	5000 次 块长=max(H,min(季节周期,24))

6.3 评价指标

$$MSE = (1 / NH) \sum_n \sum_h (y_{n,h} - \hat{y}_{n,h})^2 \quad (7)$$

同时报告 MAE 与 RMSE。MSE、MAE、RMSE 均在各领域训练期标准化空间计算，因此同一任务内可比较模型，不把 Security 的绝对值与 Climate 直接比较。候选相对改善定义为 $100 \times (1 - MSE_{candidate} / MSE_{fallback})$ 。

6.4 不确定性

滑动窗口高度重叠，逐起点损失不是独立样本。本文对回退损失减候选损失做移动块 Bootstrap，块长至少为 H 并最多取 24 或季节周期，重复 5000 次，报告 2.5%与 97.5%分位数[15]。区间完全大于零表示当前重采样设定支持候选改善，完全小于零表示支持候选变差，跨零表示当前样本不足以下定论；这些测试期区间用于诊断，不用于路径选择，也未按 18 项任务再次进行多重比较校正。

表 7 路径决策段样本量与近似功效审计

领域	H	决策起点	块长	非重叠块	语义近似 MDE	频率近似 MDE
Climate	4	62	24	2	不足 3 块	不足 3 块
Climate	12	58	24	2	不足 3 块	不足 3 块
Climate	24	52	24	2	不足 3 块	不足 3 块
Energy	4	80	24	3	26.6%	32.2%
Energy	12	76	24	3	52.3%	558.9%
Energy	24	70	24	2	不足 3 块	不足 3 块
Economy	3	22	12	1	不足 3 块	不足 3 块
Economy	6	20	12	1	不足 3 块	不足 3 块
Economy	12	17	12	1	不足 3 块	不足 3 块
Traffic	3	32	12	2	不足 3 块	不足 3 块
Traffic	6	30	12	2	不足 3 块	不足 3 块
Traffic	12	27	12	2	不足 3 块	不足 3 块
Agriculture	3	26	12	2	不足 3 块	不足 3 块
Agriculture	6	24	12	2	不足 3 块	不足 3 块
Agriculture	12	21	12	1	不足 3 块	不足 3 块
Security	3	15	12	1	不足 3 块	不足 3 块
Security	6	13	12	1	不足 3 块	不足 3 块
Security	12	10	12	0	不足 3 块	不足 3 块

在 36 条候选路径中，有 32 条因决策段不足 3 个完整非重叠块而不报告近似最小可检测效应。能够估计的 4 条路径也需要约 26.6%至 558.9%的相对损失差才达到近似 80%功效。该计算基于非重叠块均值和正态近似，只是功效警示，不是正式功效证明；它说明严格门槛下的零放行结果同时受到低假阳性目标和小样本低功效影响。

7 实验结果

7.1 数值回退选择




图 2 验证期选定的数值回退专家

PatchTST 被选中 8 次，SeasonalNaive 与 AR-Ridge 各 3 次，Last 与 DLinear-M 各 2 次。经济任务全部选择 AR-Ridge，交通任务全部选择季节朴素；这说明专家选择与领域结构一致，也说明单一深度骨干不能替代简单基线。

7.2 路径资格结果




图 3 两条文本候选的验证期置换检验 p 值

共 36 条文本候选路径，其中 6 条在决策段前后两半均胜过回退，但没有一条达到 $p \leq 0.025$ 。最接近门槛的候选 $p=0.03$ ，仍按预先规则拒绝。最终 18 项任务全部输出数值回退；该结论由验证段产生，而不是看到测试结果后作出。

7.3 测试期事后诊断




图 4 未被选中文本候选的测试期相对 MSE 变化

语义候选在 13 项任务有正点估计，频率候选仅在 8 项为正；经济三项和若干安全任务损失明显增加。点估计不能绕过验证期资格，因为这相当于用测试集选择路径。




图 5 语义候选逐任务移动块 Bootstrap 区间

相对于校准选出的数值回退，语义候选有 3 项区间完全大于零，分别为 Climate H4、Climate H12 和 Agriculture H12；有 4 项完全小于零，包括 Economy H3、H6、H12 与 Security H12。由于候选还包含数值残差结构，这里只能称为完整候选路径差异，不能直接归因为文本。Traffic 三项虽有 23.35% 至 37.31% 的点估计改善，但区间均跨零，且验证期置换门槛未通过，因此不能声称已证明交通文本有效。

表 8 语义候选资格审计

领域	H	数值回退	置换 p	两段均胜	最终路径
Climate	4	PatchTST	0.26	否	回退
Climate	12	PatchTST	0.05	否	回退
Climate	24	DLinear-M	0.20	否	回退
Energy	4	PatchTST	0.76	否	回退
Energy	12	PatchTST	1.00	否	回退
Energy	24	PatchTST	1.00	否	回退
Economy	3	AR-Ridge	1.00	否	回退

领域	H	数值回退	置换 p	两段均胜	最终路径
Economy	6	AR-Ridge	0.14	否	回退
Economy	12	AR-Ridge	0.03	否	回退
Traffic	3	SeasonalNaive	0.48	否	回退
Traffic	6	SeasonalNaive	0.34	否	回退
Traffic	12	SeasonalNaive	0.23	否	回退
Agriculture	3	Last	0.55	是	回退
Agriculture	6	Last	0.53	是	回退
Agriculture	12	PatchTST	0.57	否	回退
Security	3	PatchTST	0.68	否	回退
Security	6	PatchTST	0.91	否	回退
Security	12	DLinear-M	0.95	是	回退

7.4 ETT 外部数值验证

表 9 ETTh1 与 ETTh2 外部验证

数据	H	最佳模型	MSE 均值±标准差	最佳非 Patch	改善
ETTh1	96	PatchTST-M	0.0555±0.0003	ARRidge	6.93%
ETTh1	336	PatchTST-M	0.0851±0.0009	ARRidge	12.36%
ETTh1	720	PatchTST-M	0.0905±0.0014	SeasonalNaive24	27.73%
ETTh2	96	PatchTST-M	0.1276±0.0009	ARRidge	0.86%
ETTh2	336	PatchTST-M	0.2151±0.0011	ARRidge	7.13%
ETTh2	720	PatchTST-M	0.2382±0.0039	SeasonalNaive24	21.12%




图 6 ETT 外部基准结果

PatchTST-M 在六项 ETT 任务全部取得最低 MSE，相对最佳非 PatchTST 基线平均改善 12.69%。这是单目标 OT 协议，不能与使用全通道平均指标的论文表格直接拼接；其作用是验证本项目的数值训练与评估管线。

8 稳健性与误差分析

8.1 输入扰动




图 7 数值模型在四类输入扰动下的相对退化

PatchTST 对 0.10 标准差高斯噪声和 10%随机缺失的平均 MSE 退化为 3.31%和 1.68%，但对 2%尖峰和末段 12 步连续缺失分别退化 84.38%和 24.59%。系统应用时应增加尖峰检测，并在窗口尾部连续缺失时降低深度预测置信度。

8.2 分布漂移与失败案例




图 8 Security 目标在时间切分后的分布漂移

Security 测试段相对训练段发生明显尺度漂移，标准化测试误差远高于其他领域；文本候选不能稳定修正这种漂移。该现象说明冻结语义编码与线性残差并不具备因果适配能力，报告不能把相关文本当作导致目标变化的证据。

8.3 文本增量归因与置换敏感性




图 9 文本候选相对匹配容量纯数值残差对照的测试期差异

匹配容量对照保持与候选相近的数值残差结构，但移除文本向量、质量特征和频率语义交互。36 条候选中，仅 Climate H4 和 H12 的语义候选区间完全大于零，共 2 条；9 条区间完全小于零，其余跨

零。Agriculture H12 相对数值回退的较大改善在匹配对照下几乎消失，说明此前差异主要来自残差结构而非可识别的文本增量。




图 10 保留时间结构的 999 次循环移位置换敏感性

999 次循环移位将原校准得到的 Ridge 正则系数固定，只改变文本与数值起点的相对位置。没有候选达到 $p \leq 0.025$ ，与冻结协议的零放行结论一致。Climate H4 频率、Climate H24 语义和 Traffic H3 频率的 p 值为 0.035 至 0.042，低于 0.05 但高于预设阈值，只能视为后续数据上的待验证线索。

8.4 消融与边界

频率候选只有 8/18 项获得相对数值回退的正点估计，少于语义候选的 13/18 项，并在多个任务扩大损失。相对于匹配容量对照，频率候选也没有形成稳定优势。频率交互因此保留为被检验但未启用的候选，不写成有效创新。当前验证段较短，严格门槛降低了假阳性，也可能提高假阴性；未来可在更多独立领域上预注册同一规则，而不是在当前测试集放宽阈值。

9 系统实现与可复现性

9.1 软件结构

表 10 项目目录与职责

目录	内容
references/external	固定提交的 Time-MMD ETT 与参考实现
data_processed	时点文本索引 句向量与语义缓存
src	审计 基线 深度模型 文本候选 选择 汇总与检查

目录	内容
outputs	逐起点预测 指标 协议 表格 图形 日志 模型
paper	第 4 周 第 10 周 最终报告与渲染检查
prototype	交互式任务结果浏览器
docs	数据审计 协议冻结 文献核验 最终检查

9.2 复现链

复现顺序为：数据审计与排序检查、时点语料构建、文本编码与语义缓存、数值专家和文本候选训练、冻结选择、匹配容量对照与循环移位敏感性、结果汇总与制图、报告与原型生成。每一步输出到新目录，不覆盖原始数据。protocol.json 记录冻结主实验的划分、种子、模型、置换次数、阈值和 Bootstrap 设置；reviewer_sensitivity_summary.json 单独记录审查后敏感性分析，避免与预注册式主结果混写。

9.3 计算环境

实验在 Windows 环境完成，使用 Python、PyTorch、pandas、scikit-learn、sentence-transformers 与 matplotlib；深度训练使用 NVIDIA RTX 5070 Laptop GPU。依赖版本记录在 requirements.txt，README 给出统一命令。源数据不因体积与许可直接嵌入文档，支撑材料记录来源 URL 与固定提交。

10 模型评价与结论

10.1 主要结论

- 在当前六领域 18 项任务和冻结门槛下，没有文本路径获得部署资格，系统全部回退至验证期选定的数值专家。
- 相对于匹配容量纯数值残差对照，只有 Climate H4 和 H12 的语义候选区间完全支持改善，同时 9 条候选区间支持变差，不能概括为文本普遍有效。
- 999 次循环移位置换仍无候选达到 $p \leq 0.025$ ，说明零放行结论不依赖逐行随机置换这一种反事实构造。
- 频率语义交互没有形成跨领域稳定增益，作为否定消融结果保留。
- 数值专家的优胜者随领域变化；PatchTST 在 ETT 六项任务上表现最好，但在 Time-MMD 并非所有任务最优。
- 路径决策段在 32/36 条候选上不足 3 个完整非重叠块，因此零放行同时反映严格门槛与低统计功效，不能写成文本普遍无效。

10.2 优点

模型直接回答何时启用文本，数据处理链可审计，公式与代码一致，包含简单基线、匹配容量对照、两类错位置换、消融、跨领域确认、外部数据、三随机种子和输入扰动。选择器允许否定结论，使系统价值不依赖于事后挑选成功任务。

10.3 局限

第一，Time-MMD 的 `end_date` 不能证明真实发布时间，时点安全仍依赖代理假设；第二，验证期约 5% 的两段样本在少样本领域统计功效很低，32/36 条候选不足 3 个完整非重叠块；第三，冻结 MiniLM 和线性残差只检验轻量语义增量，不能代表所有多模态结构；第四，主协议的 99 次逐行置换分辨率较粗且不保留时间依赖，虽然 999 次循环移位得到一致的零放行结论，仍需更多独立时间段复核；第五，任务目标和采样频率不同，跨领域平均改善只适合计数或相对指标；第六，当前结论为预测相关性，不构成因果解释。

10.4 改进方向

下一步应优先获得可核验发布时间或引入 7 天、30 天、60 天发布滞后敏感性；在新增领域上预注册并复用同一资格规则；用滚动起点评估增加独立决策区间，并预先报告最小可检测效应；将预测精度与错误启用风险组成 Pareto 选择，而不是在当前测试集放宽阈值；针对尖峰和连续缺失增加异常检测与缺失掩码。只有在新增数据上通过门槛，才考虑使用更大语言模型或端到端跨模态网络。

参考文献

- [1] Liu H, Xu S, Zhao Z, et al. Time-MMD: Multi-Domain Multimodal Dataset for Time Series Analysis. *Advances in Neural Information Processing Systems, Datasets and Benchmarks Track*, 2024. DOI: 10.52202/079017-2476.
- [2] Nie Y, Nguyen N H, Sinthong P, Kalagnanam J. A Time Series is Worth 64 Words: Long-term Forecasting with Transformers. *International Conference on Learning Representations*, 2023.
- [3] Zeng A, Chen M, Zhang L, Xu Q. Are Transformers Effective for Time Series Forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 2023, 37(9):11121-11128. DOI: 10.1609/aaai.v37i9.26317.
- [4] Wu H, Hu T, Liu Y, et al. TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis. *International Conference on Learning Representations*, 2023.
- [5] Zhang Y, Yan J. Crossformer: Transformer Utilizing Cross-Dimension Dependency for Multivariate Time Series Forecasting. *International Conference on Learning Representations*, 2023.
- [6] Zhou T, Ma Z, Wen Q, et al. FEDformer: Frequency Enhanced Decomposed Transformer for Long-term Series Forecasting. *Proceedings of the 39th International Conference on Machine Learning*, PMLR 162:27268-27286, 2022.
- [7] Liu Y, Hu T, Zhang H, et al. iTransformer: Inverted Transformers Are Effective for Time Series Forecasting. *International Conference on Learning Representations*, 2024.
- [8] Wang Y, Wu H, Dong J, et al. TimeXer: Empowering Transformers for Time Series Forecasting with Exogenous Variables. *Advances in Neural Information Processing Systems*, 2024. DOI: 10.52202/079017-0015.

- [9] Jin M, Wang S, Ma L, et al. Time-LLM: Time Series Forecasting by Reprogramming Large Language Models. International Conference on Learning Representations, 2024.
- [10] Reimers N, Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. EMNLP-IJCNLP, 2019:3982-3992. DOI: 10.18653/v1/D19-1410.
- [11] Wang W, Wei F, Dong L, et al. MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers. Advances in Neural Information Processing Systems, 2020.
- [12] Liu C, Xu Q, Miao H, et al. TimeCMA: Towards LLM-Empowered Multivariate Time Series Forecasting via Cross-Modality Alignment. Proceedings of the AAAI Conference on Artificial Intelligence, 2025, 39(18):18780-18788. DOI: 10.1609/aaai.v39i18.34067.
- [13] Chowdhury A M, Akter R, Arib S H. T3Time: Tri-Modal Time Series Forecasting via Adaptive Multi-Head Alignment and Residual Fusion. Proceedings of the AAAI Conference on Artificial Intelligence, 2026, 40(25):20597-20605. DOI: 10.1609/aaai.v40i25.39196.
- [14] Spectral Text Fusion for Multimodal Time Series Forecasting. arXiv:2602.01588, 2026. 预印本.
- [15] Künsch H R. The Jackknife and the Bootstrap for General Stationary Observations. The Annals of Statistics, 1989, 17(3):1217-1241. DOI: 10.1214/aos/1176347265.

附录 A 关键结果复核

18 项任务的完整 MSE、MAE、RMSE、相对改善、移动块区间、路径 p 值和分段判定分别保存在 safefame_v2_metrics.csv 与 safefame_v2_selection_audit.csv。循环移位、匹配容量对照和功效审计保存在 reviewer_sensitivity_results.csv。正文表格为这些文件的直接汇总。

表 A1 语义候选完整测试指标

领域	H	MSE	MAE	RMSE	相对改善	块区间
Climate	4	0.1366	0.2767	0.3696	22.04%	[0.0073, 0.0648]
Climate	12	0.4372	0.5080	0.6612	35.20%	[0.0337, 0.4378]
Climate	24	0.7785	0.6700	0.8823	11.64%	[-0.1938, 0.4558]
Energy	4	0.0174	0.0867	0.1319	7.15%	[-0.0003, 0.0034]
Energy	12	0.0872	0.2114	0.2952	3.59%	[-0.0050, 0.0094]
Energy	24	0.1798	0.3131	0.4240	1.56%	[-0.0126, 0.0139]
Economy	3	0.1808	0.3262	0.4252	-51.98%	[-0.1420, -0.0114]
Economy	6	0.2367	0.3857	0.4865	-59.01%	[-0.1709, -0.0265]
Economy	12	0.4193	0.5207	0.6475	-108.10%	[-0.3891, -0.0869]
Traffic	3	0.0770	0.1356	0.2775	37.31%	[-0.0007, 0.1202]
Traffic	6	0.0880	0.1478	0.2967	29.98%	[-0.0003, 0.1033]

领域	H	MSE	MAE	RMSE	相对改善	块区间
Traffic	12	0.1009	0.1646	0.3176	23.35%	[-0.0008, 0.0859]
Agriculture	3	0.0397	0.1441	0.1991	2.40%	[-0.0003, 0.0031]
Agriculture	6	0.0798	0.1977	0.2825	4.26%	[-0.0010, 0.0110]
Agriculture	12	0.1702	0.2733	0.4126	33.79%	[0.0202, 0.1892]
Security	3	90.2702	4.4559	9.5011	-23.81%	[-71.6279, 17.6762]
Security	6	73.5979	4.3086	8.5789	5.38%	[-16.4127, 27.7007]
Security	12	85.1986	4.8523	9.2303	-18.01%	[-32.1596, -1.4681]

附录 B 课程要求落实清单

表 B1 课程设计规范落实

课程要求	交付位置	状态
完整问题描述	正文第 1 章	完成
系统或实验设计	第 5 至 6 章	完成
算法设计描述	第 5 章公式与步骤	完成
实验结果及分析图表	第 7 至 8 章	完成
源代码	src 目录与支撑材料	完成
详细实验数据和过程资料	outputs 与 docs	完成
个人作业	所有交付按个人项目整理	完成
无需 PPT 展示	第 10 周改为书面中期报告	完成