

文本增强多领域时间序列预测

严格时点对齐 反事实检验与安全回退

第 4 周课程设计选题与初步技术方案

课程名称 人工智能

作业性质 个人课程设计

姓名学号 _____

提交日期 _____

摘要

本课程设计拟研究外部文本在多领域时间序列预测中的真实增益。核心问题不是简单增加文本输入，而是在严格排除未来信息后，判断文本语义何时能稳定改善预测，以及证据不足时如何退回可靠的纯数值模型。项目计划以 Time-MMD 为主数据，在气候、能源、经济、交通、农业和安全六个领域构建 18 项领域与预测跨度组合，并以 ETTh1、ETTh2 作为纯数值外部基准。候选系统由数值专家池、冻结句向量、语义残差、频率交互、文本置换检验和验证期安全选择组成。最终交付包括源代码、逐步数据审计、实验表图、书面报告和交互式原型。

本方案的可检验目标是：若文本候选不能在预先保留的验证期同时超过数值回退、通过分段稳定性和文本置换门槛，则系统不启用文本。该设计允许最终结论为否定结果，从而避免只报告成功案例。

关键词 多模态时间序列 时点对齐 反事实检验 安全融合 负迁移

目录

- 1 选题背景与问题定义
- 2 文献调研与方案取舍
- 3 数据与任务设计
- 4 初步算法方案
- 5 实验与验证计划
- 6 进度安排 风险与交付
- 参考文献

1 选题背景与问题定义

1.1 研究对象

现实预测通常同时面对历史数值序列与新闻、报告、政策或事件文本。文本可能解释数值突变，但也可能晚于预测时点、偏离主题或重复既有趋势。Time-MMD 提供多领域成对数据，为这一问题提供实验基础[1]。本项目将文本视为受信息可得性约束的外生变量，而不是默认有效的额外模态。

1.2 拟解决的具体问题

- 在文本结束时间早于预测起点的约束下，语义特征能否超过纯数值基线。
- 正确对齐文本能否优于随机置换文本，以排除模板结构、文本数量和时间趋势造成的伪增益。
- 频域统计与文本语义交互是否在较长预测跨度更有效。
- 当文本质量或稳定性不足时，能否用冻结规则自动回退到数值专家。
- 数值骨干在独立 ETT 数据与输入扰动下是否保持可复现性能。

1.3 输入 输出与边界

输入为长度 L 的历史数值窗口 X 和预测时点前可获得的事实集合 Z ；输出为未来 H 步目标序列。数据中的 `end_date` 仅作为可得时间代理，不能等同于真实发布时间；包含未来预测内容的 `preds` 字段不进入模型。

$$\tilde{x}_t = (x_t - \mu_{\text{train}}) / \sigma_{\text{train}} \quad (1)$$

2 文献调研与方案取舍

表 1 相关研究 证据等级与本文取舍

研究	身份	主要启发	本文使用边界
Time-MMD	NeurIPS 2024	多领域数值与文本对齐数据	提供数据基础；不照抄其结论
DLinear	AAAI 2023	分解线性预测与强简单基线	作为可解释深度基线
PatchTST	ICLR 2023	分块与通道独立	作为主要数值专家
TimesNet / FEDformer	ICLR 2023 / ICML 2022	多周期与频域建模	启发频率统计分支
TimeXer	NeurIPS 2024	外生变量建模	支持将文本视为外生信息
Time-LLM / TimeCMA	ICLR 2024 / AAAI 2025	语言模型重编程与跨模态对齐	说明融合方法空间；本文采用轻量实现
T3Time	AAAI 2026	时域 频域 提示三分支与跨度条件门控	借鉴多模态和跨度条件思想
Spectral Text Fusion	2026 预印本	频谱与文本交互	启发候选频率交互；须独立验证

数值侧从 Last、季节朴素和 AR-Ridge 起步，再加入 DLinear 与 PatchTST[2-3]。频率分支受 TimesNet 与 FEDformer 的多周期和频域思想启发[4,6]，但只构造低维频率统计和交互，避免复制大型结构。文本侧使用冻结 MiniLM 句向量[10-11]，以受正则化残差模型检验是否存在增量信息。Time-LLM、AAAI 2025 的 TimeCMA 与 AAAI 2026 的 T3Time 提供语言重编程、跨模态对齐和三分支融合依据[9,12-13]；Spectral Text Fusion 仍为预印本[14]，仅作为频谱交互启发。

3 数据与任务设计

表 2 Time-MMD 六领域数据审计结果

领域	行数	数值列	起始	结束	重排数	OT 缺失
Agriculture	532	3	1980-01	2024-04	0	0
Climate	1272	8	2000-01	2024-05	1272	0
Economy	447	3	1987-01	2024-03	447	0
Energy	1622	9	1993-04	2024-04	0	0
Security	309	1	1998-09	2024-05	0	0

领域	行数	数值列	起始	结束	重排数	OT 缺失
Traffic	651	1	1970-01	2024-03	0	0

气候文件原为倒序，经济文件顺序混乱，建模前必须按解析后的时间稳定升序排序。六领域目标 OT 均无缺失；Security 仅有一个数值变量且样本最少，适合作为分布漂移和少样本压力测试。文本仅使用 fact，按同来源和规范化文本去重，最多保留每来源 32 条最近事实。

表 3 任务与评价口径

数据	任务数	划分	主要指标	用途
Time-MMD 六领域	18	70%训练 10%验证 20%测试	标准化 MSE MAE RMSE	主实验
ETTh1 ETTh2	6	固定时间划分	标准化 MSE 与三种子均值	外部数值验证
输入扰动	24	高斯 缺失 尖峰 尾段缺失	相对退化率	稳健性

4 初步算法方案

4.1 数值专家池

候选专家包括 Last、SeasonalNaive、AR-Ridge、DLinear-M 和 PatchTST。简单模型提供可解释下限，深度模型固定 2026、2027、2028 三个随机种子。数值专家仅在验证期前半段比较，测试集不参与选择。

4.2 严格时点语义表征

对每个预测起点，仅索引历史窗口内且 end_date 早于预测起点的 fact。每条文本经冻结 all-MiniLM-L6-v2 编码；同来源向量按时间衰减加权平均并做 L2 归一化。历史窗口长度的四分之一作为半衰期。

$$m^* = \arg \min_m \text{MSE_calibration}(m) \tag{2}$$

4.3 残差候选与安全选择

语义候选以 Last 预测为锚点，使用 Ridge 学习由数值窗口、文本语义和质量特征共同解释的残差；频率候选再加入历史窗口频谱统计与语义交互。由于候选锚点与最终数值回退可能不同，候选相对回退的改善不能单独归因于文本，必须结合匹配容量纯数值残差对照和文本错位置换解释。验证期再对半：前半选择正则系数和数值专家，后半只作路径资格判定。候选必须同时满足后半总体优于回退、前后两段均获胜、99 次文本置换检验经 Bonferroni 校正后 $p \leq 0.025$ 。

$$z_t = \text{Normalize}(\sum_i w_i e_i / \sum_i w_i), \quad w_i = \exp(-\ln 2 \cdot \text{age}_i / \tau) \tag{3}$$

$$\hat{\delta} = \arg \min_{\delta} \{ \sum_i \|Y_t - \text{Last}(X_i) - \Phi(X_i, Z_i, q_i) \delta\|_2^2 + \alpha \|\delta\|_2^2 \} \tag{4}$$

5 实验与验证计划

表 4 实验矩阵与成功标准

实验	对照	验证方式	预先判据
数值基线	5 类专家	时间顺序留出 三随机种子	报告全部模型 不只报告赢家
语义增量	语义候选 对 数值回退	独立路径决策段	总体和两分段均更优
文本反事实	对齐文本 对 错位文本	99 次冻结置换 加循环移位敏感性	$p \leq 0.025$
测试不确定性	逐预测起点配对损失	5000 次移动块 Bootstrap	报告 95% 区间
消融	无频率 对 频率交互	同一划分同一回退	不以单任务胜利概括总体
稳健性	干净输入 对 四类扰动	三次重复	报告均值和标准差

由于滑动预测窗口相互重叠，普通独立同分布 Bootstrap 会低估不确定性，因此使用移动块 Bootstrap 保留局部依赖[15]。评价价值均在训练期均值与标准差定义的标准化空间计算；不同领域的绝对 MSE 不直接横向比较。

6 进度安排 风险与交付

表 5 第 4 周以后实施计划

周次	主要工作	验收证据
第 4 至 6 周	数据审计 时点索引 简单基线	审计表 自检日志 基线结果
第 7 至 9 周	DLinear PatchTST 文本编码与开发实验	三种子模型 训练日志 开发图表
第 10 周	书面中期检查 冻结最终协议	中期报告 协议 JSON 风险清单
第 11 至 14 周	六领域确认实验 ETT 外部验证 稳健性	测试结果 区间估计 消融表
第 15 至 17 周	报告 原型 支撑材料 审稿检查	DOCX PDF 代码 数据清单 校验报告

主要风险包括文本真实发布时间缺失、搜索文本主题漂移、验证样本较少、不同领域尺度不一致和深度模型随机性。对应措施是把 end_date 明确表述为代理变量、保留文本置换与缺失指示、按领域标准化、固定三随机种子并报告限制。少样本任务另报告决策起点数、非重叠块数和近似最小可检测效应。若文本未通过门槛，否定结果仍作为完整结论，不临时放宽标准。

最终交付文件

- 第4周选题与初步技术方案；
- 第10周书面中期进展报告；
- 最终课程设计报告 DOCX 与 PDF；
- 完整 Python 源代码、依赖与统一运行说明；
- 原始数据来源和固定提交信息、处理后审计表、实验明细与图表；
- 交互式结果原型、文件哈希与最终检查报告。

参考文献

- [1] Liu H, Xu S, Zhao Z, et al. Time-MMD: Multi-Domain Multimodal Dataset for Time Series Analysis. Advances in Neural Information Processing Systems, Datasets and Benchmarks Track, 2024. DOI: 10.52202/079017-2476.
- [2] Nie Y, Nguyen N H, Sinthong P, Kalagnanam J. A Time Series is Worth 64 Words: Long-term Forecasting with Transformers. International Conference on Learning Representations, 2023.
- [3] Zeng A, Chen M, Zhang L, Xu Q. Are Transformers Effective for Time Series Forecasting? Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(9):11121-11128. DOI: 10.1609/aaai.v37i9.26317.
- [4] Wu H, Hu T, Liu Y, et al. TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis. International Conference on Learning Representations, 2023.
- [5] Zhang Y, Yan J. Crossformer: Transformer Utilizing Cross-Dimension Dependency for Multivariate Time Series Forecasting. International Conference on Learning Representations, 2023.
- [6] Zhou T, Ma Z, Wen Q, et al. FEDformer: Frequency Enhanced Decomposed Transformer for Long-term Series Forecasting. Proceedings of the 39th International Conference on Machine Learning, PMLR 162:27268-27286, 2022.
- [7] Liu Y, Hu T, Zhang H, et al. iTransformer: Inverted Transformers Are Effective for Time Series Forecasting. International Conference on Learning Representations, 2024.
- [8] Wang Y, Wu H, Dong J, et al. TimeXer: Empowering Transformers for Time Series Forecasting with Exogenous Variables. Advances in Neural Information Processing Systems, 2024. DOI: 10.52202/079017-0015.
- [9] Jin M, Wang S, Ma L, et al. Time-LLM: Time Series Forecasting by Reprogramming Large Language Models. International Conference on Learning Representations, 2024.
- [10] Reimers N, Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. EMNLP-IJCNLP, 2019:3982-3992. DOI: 10.18653/v1/D19-1410.
- [11] Wang W, Wei F, Dong L, et al. MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers. Advances in Neural Information Processing Systems, 2020.
- [12] Liu C, Xu Q, Miao H, et al. TimeCMA: Towards LLM-Empowered Multivariate Time Series Forecasting via Cross-Modality Alignment. Proceedings of the AAAI Conference on Artificial Intelligence, 2025, 39(18):18780-18788. DOI: 10.1609/aaai.v39i18.34067.
- [13] Chowdhury A M, Akter R, Arib S H. T3Time: Tri-Modal Time Series Forecasting via Adaptive Multi-Head Alignment and Residual Fusion. Proceedings of the AAAI Conference on Artificial Intelligence, 2026, 40(25):20597-20605. DOI: 10.1609/aaai.v40i25.39196.
- [14] Spectral Text Fusion for Multimodal Time Series Forecasting. arXiv:2602.01588, 2026. 预印本.

[15] Künsch H R. The Jackknife and the Bootstrap for General Stationary Observations. The Annals of Statistics, 1989, 17(3):1217-1241. DOI: 10.1214/aos/1176347265.